

PIPELINE DATA & SCORING – PLATEFORME IMMOBILIÈRE

Version MVP – France – RGPD by design

1. Objectif du pipeline

Fournir des données **propres, fiables et auditable**s pour le moteur de décision.

Garantir des **scores explicables** et des **comparables précis**, en conformité avec le cadre légal français et le RGPD.

Livrables attendus :

- Comparables précis
 - Fourchette de valeur
 - Scores décisionnels
-

2. Couches du pipeline

2.1 Raw Data Layer

- Sources : DVF, DPE ADEME, INSEE IRIS, Cadastre, IGN
- Stockage brut et immuable
- Versionning systématique

2.2 Clean Data Layer

- Normalisation des formats (prix, surface, dates)
- Déduplication des transactions

- Géocodage précis
- Harmonisation typologie

2.3 Derived Data Layer

- Calcul des **zones de valeur**
 - Sélection et scoring des comparables
 - Estimations automatiques
 - Indices décisionnels : tension, liquidité, volatilité
 - Historique et versioning des calculs
-

3. Processus détaillé

1. Ingestion

- Collecte automatisée des sources open data et partenaires
- Validation des droits et consentements

2. Nettoyage

- Déduplication, géocodage, correction des incohérences
- Journalisation complète

3. Enrichissement

- Ajout de champs dérivés
- Calcul de scores explicables

4. Stockage

- PostgreSQL + PostGIS
- Versioning tables et calculs

5. Distribution

- API REST sécurisée
 - Cache Redis < 300ms
 - Export interne pour reporting / audits
-

4. Modèle de scoring

- **Valeur marché** : médiane pondérée des comparables + ajustements explicites
- **Tension locale** : ventes récentes vs offres disponibles
- **Liquidité** : durée moyenne sur le marché par zone
- **Risque énergétique** : impact DPE sur prix
- **Score global** : combinaison pondérée des 4 indicateurs

Tous les calculs sont versionnés et auditables.

5. Gouvernance et conformité

- Traçabilité complète de l'origine des données
 - Journalisation de chaque traitement
 - Respect strict RGPD : consentement, droit d'accès, suppression
 - Auditabilité CNIL & usage interne
-

6. Monitoring et maintenance

- Alertes sur anomalies de données

- Mise à jour automatique des couches data
 - Versioning du modèle et des scores
 - Logs pour debug et reporting légal
-

7. Output attendu

- Comparables précis par bien
- Fourchette de valeur marché : min / médian / max
- Scores décisionnels : valeur, tension, liquidité, énergie, global
- Données prêtes à l'usage pour frontend, API et reporting